



Predykcja Wyników **Meczów** **Piłkarskich**

Analiza algorytmów ML, implementacja i optymalizacja hiperparametrów w celu pokonania losowości w piłce nożnej.

Kacper Kajko, Szymon Stefanowicz, Krystian Zaręba

Opis zbioru danych

Baza: Kaggle Soccerway


Zestaw danych obejmuje historyczne wyniki oraz szczegółowe statystyki z tysięcy rozegranych spotkań na całym świecie (109 kolumn, około 17 tysięcy rekordów). Jest wysoce **adekwatny** do zdefiniowanego problemu predykcyjnego.

Dane te umożliwiają zastosowanie algorytmów uczenia maszynowego do rozwiązania problemu wieloklasowej klasyfikacji (1, X, 2).


DAYS USING MEDIAN



START RENDER VS BOUNCE RATE



SESSIONS




Analiza zbioru danych: zmienne


W zbiorze znajdują się szczegółowe dane z historycznych meczów piłkarskich. Można je podzielić na cztery główne kategorie:

- **Dane identyfikacyjne i kontekstowe:** Data rozegrania meczu (date), nazwa ligi/rozgrywek (league_division) oraz nazwy zespołów (home_team, away_team).
- **Zmienna objaśniana (Target):** Końcowy rezultat meczu (result), kodowany w modelu na trzy klasy: wygrana gości (0), remis (1), wygrana gospodarzy (2).
- **Ogólna ocena siły zespołów:** Ogólny ranking/ocena drużyny przed meczem (home_team_rating, away_team_rating).
- **Statystyki meczowe (dla gospodarzy i gości):**
 - Gole (goals) oraz współczynnik goli oczekiwanych (xg).
 - Strzały ogólne (shots_total) oraz strzały celne (shots_on_target).
 - Procentowe posiadanie piłki (possession_pct).
 - Rzuty różne (corners).
 - Interwencje bramkarzy (goalkeeper_saves).

Analiza zbioru danych: przed filtracją



Analiza zbioru danych: Macierz korelacji



Analiza zbioru danych: przed filtracją

[A] Podstawowe statystyki meczowe (dane surowe):

	home_goals	away_goals	home_xg	away_xg	home_possession_pct	away_possession_pct
count	12909.00	12909.00	11528.00	11528.00	12883.0	12883.0
mean	1.53	1.23	1.50	1.20	51.3	48.7
std	1.27	1.15	0.85	0.75	10.8	10.8
min	0.00	0.00	0.00	0.00	17.0	15.0
25%	1.00	0.00	0.87	0.63	44.0	41.0
50%	1.00	1.00	1.37	1.06	51.0	49.0
75%	2.00	2.00	1.97	1.61	59.0	56.0
max	9.00	9.00	6.13	6.44	85.0	83.0

[B] Skośność rozkładu (Skewness) – sprawdzenie odstępstw od rozkładu normalnego:

Gole Gospodarzy: 0.93

Gole Gości: 1.05

(Wartości > 1 oznaczają silną prawostronną asymetrię – większość meczów kończy się małą liczbą goli)

[C] Statystyki wyliczonych wskaźników formy długoterminowej (Przewaga Gospodarzy):

	diff_goals10	diff_xg10	diff_rating10
count	12862.00	11415.00	12848.00
mean	-0.02	-0.02	0.01
std	0.77	0.54	0.35
min	-6.00	-3.42	-2.30
25%	-0.50	-0.35	-0.20
50%	0.00	-0.01	0.01
75%	0.44	0.32	0.23
max	6.00	3.53	3.50

[D] Procent brakujących danych w kluczowych kolumnach (Top 5):

home_headed_goals	70.28 %
away_headed_goals	70.28 %
home_errors_leading_to_goal	38.55 %
away_errors_leading_to_goal	38.55 %
away_errors_leading_to_shot	38.49 %
dtype: object	

Analiza zbioru danych: przed filtracją



Zjawisko „przewagi własnego boiska”

Analiza danych surowych statystycznie potwierdza przewagę gospodarzy (średnio **1.53** gola vs **1.23** dla gości) oraz wyższe wartości xG.



Skośność rozkładu (Skewness)

Wskaźnik asymetrii **~1.0** dowodzi, że rozkład bramek nie jest normalny. Dominacja niskich wyników czyni sport wysoce stochastycznym.



Wyrównany poziom rozgrywek

Średnia różnica formy (`diff_goals10`) oscyluje wokół zera (**-0.02**), co wskazuje na wyrównany poziom sportowy po filtracji.



Uzasadnienie selekcji cech

Odrzucono zbyt szczegółowe statystyki z powodu braków danych (**70% NaN**), co zapewnia większą stabilność modelu.

Analiza zbioru danych

Postępowanie z brakami w danych (NaN)

Program radzi sobie z brakującymi wartościami dwuetapowo, stosując podejście hybrydowe (usuwanie oraz uzupełnianie):

- **Całkowite usunięcie (dla kluczowych zmiennych):** Jeśli brakuje informacji fundamentalnych (data, wynik, rolling rating), wiersz jest bezpowrotnie kasowany za pomocą funkcji `.dropna()`.
- **Uzupełnianie medianą (SimpleImputer):** Dla pozostałych cech statystycznych w macierzy X (takich jak brakujące xG, liczba strzałów czy rzutów różnych w starszych meczach), kod stosuje klasę `SimpleImputer(strategy="median")`.
- **Zasada braku wycieku danych:** Algorytm oblicza medianę **wyłącznie na podstawie zbioru treningowego** (`fit_transform`), a następnie aplikuje te same wartości do zbioru testowego (`transform`). Dzięki temu brakujące wartości są łątane statystycznie najbardziej "środkową" wartością dla danej ligi/cechy, a modele uczenia maszynowego nie wywalają błędów z powodu pustych komórek.

Analiza zbioru danych


Przetwarzanie i filtrowanie danych

Kod przygotowuje dane w sposób chronologiczny i odrzuca "szum" statystyczny poprzez potrójny mechanizm filtracji:

- **Weryfikacja poprawności:** Na samym początku usuwa wiersze, które nie posiadają **wyniku meczu** (`result`). Następnie sortuje dane od najstarszych do najnowszych, aby zachować ciągłość osi czasu.
- **Filtrowanie mało popularnych lig:** Kod odrzuca całe ligi, które w całym zbiorze danych posiadają mniej niż **200 meczów** (`MIN_LEAGUE_GAMES`). Pozwala to modelowi uczyć się na stabilnych i dobrze udokumentowanych rozgrywkach.
- **Filtrowanie rzadkich drużyn:** Usuwane są mecze z udziałem zespołów, które rozegrały łącznie mniej niż **10 spotkań** (`MIN_TEAM_GAMES`). Dzięki temu eliminowane są np. drużyny, które zaliczyły tylko epizod w danej lidze lub pucharach, co uniemożliwiłoby rzetelne wyliczenie ich formy.
- **Odcięcie "okna startowego":** Usuwamy mecze z samego początku osi czasu, ponieważ służą one wyłącznie do zbudowania pierwszej historii (średnich kroczących) dla drużyn, a model nie może uczyć się na wierszach z brakującymi danymi o formie.

Analiza zbioru danych: po filtracji

Rozkład wyników w zbiorze danych



Aktualny stan wiedzy

Analiza współczesnego stanu wiedzy dedykowanego predykcji wyników sportowych.

Próg losowości a możliwości ML

Badania naukowe (m.in. Rodrigues i Pinto, 2022) udowadniają, że uczenie maszynowe potrafi znacząco przebić barierę ślepego trafu (33.3%). W optymalnych warunkach algorytmy potrafią osiągać dokładność predykcji przekraczającą 60%.

Kluczowa rola inżynierii cech

Przeglądy literaturowe (np. Bunker & Thabtah) podkreślają, że surowe wyniki to za mało. Sukces modeli zależy od odpowiedniej agregacji danych z poprzednich meczów (tzw. *rolling averages*) oraz wskaźników różnicowych między zespołami.

Problem remisów jako bariera

Literatura zgodnie wskazuje remisy jako wysoce stochastyczne (losowe) anomalie, co narzuca na badaczy konieczność stosowania specjalnych wag (class balancing) oraz innych metryk niż standardowe *Accuracy*.

Naukowe uzasadnienie wyboru

Nasza selekcja 4 algorytmów wynika z analizy artykułów. Badacze zalecają testowanie zróżnicowanych paradygmatów: od modeli liniowych, przez KNN, aż po modele zespołowe (Random Forest, XGBoost).

“

*Zastosowanie modeli uczenia
maszynowego opartych na krótko- i
długoterminowych statystykach pozwala
na predykcję wyniku meczu,
przekraczając klasyczny próg losowości
(33%).*

”

— Hipoteza Badawcza Projektu

Analiza Potencjalnych Kandydatów

Logistic Regression

Random Forest

k-Nearest Neighbours

XGBoost (Gradient Boosting)

Wybraliśmy te cztery modele jako głównych kandydatów, z których każdy reprezentuje inną perspektywę analityczną: **Regresja Logistyczna** skupia się na wykrywaniu prostych i logicznych zależności statystycznych. **Random Forest** stawia na stabilność oraz „mądrość grupową”, co pozwala uodpornić model na anomalie i nietypowe wyniki. **XGBoost** to kandydat nastawiony na najwyższą precyzję, zdolny do wychwytywania bardzo skomplikowanych i ukrytych schematów w danych. Z kolei **kNN** opiera się na koncepcji „powtarzalności historii”, szukając w przeszłości spotkań o niemal identycznych profilach statystycznych. To zestawienie pozwala spojrzeć na problem predykcji wielowymiarowo — od prostych reguł, przez złożone wzorce, aż po analogię historyczną

Logistic Regression

Sposób działania: Algorytm z rodziny uogólnionych modeli liniowych (GLM). Przetwarza kombinację liniową cech wejściowych przez funkcję sigmoidalną (lub *softmax* dla klasyfikacji wieloklasowej 1X2), mapując wynik na prawdopodobieństwa z przedziału $[0, 1]$.

Zalety: Oferuje maksymalną interpretowalność – wagi przypisane do konkretnych cech (np. różnicy xG) pozwalają wprost ocenić ich wpływ na wynik. Cechuje się niską wariancją (*low variance*) i wyjątkowo szybką zbieżnością podczas optymalizacji.

Wady: Posiada wysokie obciążenie (*high bias*), co oznacza, że zakłada liniową separowalność klas. Nie potrafi samodzielnie wychwytywać złożonych interakcji między statystykami.

Dopasowanie do danych: Idealny kandydat na tzw. *baseline model*. Weryfikuje podstawową hipotezę projektu: czy wynik meczu można przewidzieć wyłącznie na podstawie najprostszych, liniowych trendów wzrostowych/spadkowych w formie zespołów.

Random Forest

Sposób działania: Algorytm typu *ensemble*, wykorzystujący technikę *Bootstrap Aggregating* (bagging). Generuje setki nieskorelowanych drzew decyzyjnych, uczonych na losowych podzbiorach danych i cech. Predykcja końcowa to wynik uśrednionego głosowania większościowego drzew.

Zalety: Architektura ta drastycznie redukuje wariancję modelu, rozwiązując problem przeuczenia (*overfittingu*). Naturalnie radzi sobie z nieliniowością w sporcie (np. relacja między rzutami różnymi a skutecznością) i nie wymaga rygorystycznego skalowania danych.

Wady: Słaba interpretowalność pojedynczych decyzji (struktura „czarnej skrzynki”) oraz relatywnie wysokie zapotrzebowanie na pamięć operacyjną przy dużej liczbie estymatorów.

Dopasowanie do danych: Futbol charakteryzuje się nagłymi anomaliami (np. czerwona kartka zmieniająca wynik). Random Forest, dzięki uśrednianiu decyzji setek drzew, jest wysoce odporny na takie sportowe odchylenia i zaszumienie danych.

XGBoost

Sposób działania: Modele budowane są sekwencyjnie. Każde kolejne słabe drzewo decyzyjne jest dodawane po to, aby zminimalizować błędy resztkowe (*residuals*) popełnione przez poprzedników, wykorzystując algorytm spadku gradientowego (*gradient descent*).

Zalety: Osiąga najwyższą skuteczność (State-of-the-Art) dla danych tabelarycznych. Posiada zaawansowane wbudowane mechanizmy regularyzacji (L1/L2), co chroni przed zbytnim dopasowaniem się modelu do historii.

Wady: Jest niezwykle wrażliwy na hiperparametry (m.in. *learning_rate*, głębokość drzewa). Źle zestrojony XGBoost na danych sportowych błyskawicznie ulega przeuczeniu, "zapamiętując" historyczne wyniki.

Dopasowanie do danych: Rozważany jako model docelowy do maksymalizacji metryki F1. Dzięki precyzyjnemu korygowaniu błędów, ma największe szanse na wychwycenie subtelnych różnic w statystykach, które decydują o trudnych do wytypowania remisach.

k-Nearest Neighbours

Sposób działania: Algorytm oparty na instancjach. Szuka podobieństw – analizuje profil statystyczny nowego meczu i znajduje „k” najbardziej zbliżonych do niego spotkań z przeszłości. Model zakłada, że nowy mecz zakończy się takim samym wynikiem, jak większość z tych historycznych spotkań.

Zalety: Intuicyjny mechanizm oparty na logicznym założeniu (analogii). Nie wymaga skomplikowanej, długotrwałej fazy treningu matematycznego.

Wady: Jest bardzo podatny na zjawisko tzw. przekleństwa wymiarowości. Przy bardzo rozbudowanych statystykach meczowych (wiele atrybutów), matematyczne mierzenie "podobieństwa" przestaje działać poprawnie – algorytm gubi się w nadmiarze danych i wymaga ich drastycznej redukcji.

Dopasowanie do problemu: Kandydat weryfikujący założenie o „powtarzalności scenariuszy meczowych”. Sprawdza koncepcję polegającą na tym, czy mecze o bliźniaczo podobnych uwarunkowaniach statystycznych faktycznie prowadzą do takich samych rozstrzygnięć na boisku.

Implementacja Modeli Bazowych (Scikit-Learn)

Do ostatecznej implementacji wybrano dwa różne modele: Regresję Logistyczną (LR) jako wysoce interpretowalny model bazowy do wykrywania prostych zależności liniowych, oraz Las Losowy (RF) jako zaawansowany algorytm zespołowy, który świetnie radzi sobie z nieliniowymi relacjami w statystykach i jest odporny na typowy dla sportu szum informacyjny. Wybór Lasu Losowego wspiera również literatura naukowa (Rodrigues & Pinto, 2022), wskazując go jako jeden z najskuteczniejszych modeli w tej dziedzinie. Głównym wyzwaniem projektowym jest asymetria klas, ponieważ remisy stanowią zaledwie 25,4% całego zbioru danych. Z tego powodu porzucono klasyczną metrykę Accuracy na rzecz F1 Macro, co zmusiło modele do równego traktowania wszystkich wyników i zapobiegło ignorowaniu remisów przez algorytmy. Walkę z asymetrią wspiera także zastosowanie parametru `class_weight="balanced"`, który poprzez zwiększenie kar za błędne typowanie mniej licznych klas wymusza na algorytmach aktywne wykrywanie specyficznych sygnałów remisowych.

Kluczowa Metodologia Przetwarzania

Dual Window Rolling Averages

Zastosowano agregację statystyk przedmeczowych w dwóch oknach czasowych dla uchwycenia odpowiednich trendów:

- ⚡ **Krótkoterminowe (5 meczów):** Reaguje na nagłe zmiany formy (tzw. "efekt nowej miotły").
- 📈 **Długoterminowe (10 meczów):** Stabilizuje obraz rzeczywistej siły zespołu w sezonie.
- 🛡️ **Brak wycieku:** Funkcja `shift(1)` gwarantuje, że model "nie widzi" statystyk z aktualnego meczu.

Chronologiczny Podział Danych

W przeciwieństwie do standardowej kros-walidacji, podział zbioru został wykonany ściśle chronologicznie, imitując warunki produkcyjne (80/20).

- 📅 **Treningowy:** 10,327 meczów (do Gru 2025).
- 📅 **Testowy:** 2,582 mecze (od Gru 2025 do Kwi 2026).
Zapobiega to uczeniu się "z przyszłości".

Cechy wejściowe modelu(75 zmiennych)

- **Identyfikatory (3):** ID gospodarza (`h_id`), ID gościa (`a_id`) oraz ID ligi (`league_id`).
- **Forma zespołów (Gospodarze i Goście) (32):** Średnie kroczące z krótkiego (5 meczów) oraz długiego (10 meczów) okna dla: ogólnego ratingu, goli, xG, strzałów celnych, strzałów ogółem, posiadania piłki, rzutów różnych oraz obron bramkarza.
- **Różnice liniowe (`diff`) (16):** Czysta przewaga jednej ze stron (wartość gospodarzy minus wartość gości) wyliczona dla wszystkich 8 statystyk w obu oknach czasowych (5 i 10).
- **Różnice bezwzględne (`abs`) (16):** Wartości bezwzględne z różnic liniowych, pokazujące jak blisko siebie pod względem piłkarskim są oba zespoły.
- **Sygnały remisowe (`draw_signals`) (5):** Monotonicznie malejące wskaźniki bazujące na różnicach bezwzględnych (`draw_rating5/10`, `draw_goals5/10`, `draw_xg5`). Osiągają maksimum (1.0), gdy zespoły mają identyczne statystyki.
- **Stosunki sił (`ratios`) (3):** Proporcje formy gospodarzy do gości dla ratingu (`rate_ratio`), goli (`goals_ratio`) oraz xG (`xg_ratio`).

Wyzwania implementacyjne - asymetria klas

Problem: Remisy stanowią tylko 25,4% bazy danych. Klasyczne modele mają tendencję do ich ignorowania, aby sztucznie zawyżyć sobie ogólną celność (*Accuracy*) poprzez obstawianie wyłącznie wygranych.

Rozwiązanie w kodzie (Wagi): Zastosowano mechanizm `class_weight="balanced"`. Algorytm automatycznie nakłada większe kary matematyczne za błędne wytypowanie remisów, wymuszając na modelu naukę tej klasy.

Metryka sukcesu (F1 Macro): Zrezygnowano ze zwykłej celności (*Accuracy*). Głównym kryterium oceny modeli jest F1 Macro, które traktuje każdą klasę (1, X, 2) jako równie ważną, premiując modele wszechstronne.

Proces szkolenia i optymalizacja modeli

Faza 1: Starcie bazowe (Baseline): Zaimplementowane modele (Regresja Logistyczna oraz Las Losowy) są najpierw trenowane na domyślnych ustawieniach i oceniane na zbiorze testowym.

Faza 2: Automatyczna selekcja: Kod posiada mechanizm warunkowy, który porównuje wyniki obu modeli (na podstawie *F1 Macro*) i automatycznie promuje do dalszego etapu tylko ten, który poradził sobie lepiej.

Faza 3: Strojenie hiperparametrów: Zwycięski model trafia do modułu `RandomizedSearchCV`. Algorytm ten przeszukuje zdefiniowaną przestrzeń parametrów (np. siłę regularyzacji, czy maksymalną głębokość drzew), aby wycisnąć z modelu maksymalną skuteczność bez efektu przeuczenia.

Wyniki modeli bazowych: Logistic Regression

[1] Logistic Regression → Accuracy: 0.4551 | F1 Macro: 0.4351

	precision	recall	f1-score	support
Away (0)	0.4373	0.4962	0.4649	780
Draw (1)	0.3043	0.2878	0.2958	681
Home (2)	0.5622	0.5281	0.5446	1121
accuracy			0.4551	2582
macro avg	0.4346	0.4374	0.4351	2582
weighted avg	0.4565	0.4551	0.4549	2582

Wyniki modeli bazowych: Random Forest

[2] Random Forest → Accuracy: 0.4764 | F1 Macro: 0.4114

	precision	recall	f1-score	support
Away (0)	0.4428	0.5115	0.4747	780
Draw (1)	0.3038	0.1160	0.1679	681
Home (2)	0.5292	0.6708	0.5917	1121
accuracy			0.4764	2582
macro avg	0.4253	0.4328	0.4114	2582
weighted avg	0.4437	0.4764	0.4446	2582

Strojenie Modelu (Hyperparameter Tuning)

Do optymalizacji wybrano Logistic Regression ze względu na najwyższy bazowy wynik F1 Macro. Optymalizację przeprowadzono używając RandomizedSearchCV (cv=3).

Parametry poddane optymalizacji:


Siła regularyzacji (C): Od 0.001 do 10 (skala logarytmiczna).

Algorytm optymalizujący (solver): lbfgs, saga.

Typ kary (penalty): L2 (Ridge).

Best Params: {'C': 0.00168, 'penalty': 'l2', 'solver': 'saga'}

Wynik sugeruje silną potrzebę regularyzacji (bardzo małe C), co zapobiega przeuczeniu na szumiących danych sportowych.



Model: Logistic Regression (po strojeniu)

	precision	recall	f1-score	support
Away (0)	0.4334	0.5090	0.4682	780
Draw (1)	0.3086	0.2805	0.2938	681
Home (2)	0.5645	0.5272	0.5452	1121
accuracy			0.4566	2582
macro avg	0.4355	0.4389	0.4357	2582
weighted avg	0.4574	0.4566	0.4556	2582

Model	Accuracy	F1 Macro	
Logistic Regression (bazowy)	0.4551	0.4351	
Random Forest (bazowy)	0.4764	0.4114	
Logistic Regression (po strojeniu)	0.4566	0.4357	◀ NAJLEPSZY

Ostateczne Wyniki Modelu Optymalnego

45.7%

Accuracy (Zbiór
Testowy)

0.436

F1 Score (Macro)

F1 - Away (Goście)

0.468

F1 - Draw (Remis)

0.294


F1 - Home (Gosp.)

0.545

Strojenie przyniosło marginalną poprawę wyników globalnych, ale ustabilizowało model. Największym wyzwaniem pozostaje prawidłowa klasyfikacja remisów, która obniża wynik ogólny F1 Macro.

Kluczowe Zmienne (Feature Importance)

Wagi współczynników zoptymalizowanego modelu Regresji Logistycznej wskazują, które statystyki przedmeczowe miały największy wpływ na decyzję modelu.



Wniosek: Długoterminowa (10 meczów) różnica w strzelonych bramkach oraz xG (oczekiwanych golach) między zespołami to najsilniejsze predyktory wyniku.

Weryfikacja Hipotezy i Wnioski Końcowe



✓ Hipoteza Częściowo Potwierdzona

Osiągnięte Accuracy na poziomie $\sim 45.7\%$ udowadnia, że model uczy się rzeczywistych wzorców, przewyższając ślepy traf (33%) i wyłuskując przewagę z surowych danych.

Przetwarzanie danych (rolling averages, różnice xG) okazało się kluczowe dla sukcesu ekstrakcji cech.

Jednakże trudność w wykrywaniu remisów pokazuje, że na poziomie podstawowych statystyk meczowych, piłka nożna pozostaje sportem wysoce nieprzewidywalnym (stochastycznym).

Dalszy rozwój wymaga włączenia danych zawodników (jak w literaturze) lub analizy sekwencyjnej (Deep Learning).