

Predykcja Wyników Meczów Piłkarskich

Projekt Analityczno-Implementacyjny AI

Część 1: Analiza Biznesowa i Eksploracja Danych

1. Wybór Zestawu Danych

Baza: Kaggle Soccerway

Zestaw danych obejmuje historyczne wyniki oraz szczegółowe statystyki z tysięcy rozegranych spotkań na całym świecie. Jest wysoce **adekwatny** do zdefiniowanego problemu predykcyjnego.

Dane te umożliwiają głębokie zastosowanie algorytmów uczenia maszynowego (np. Random Forest, XGBoost) do rozwiązania problemu wieloklasowej klasyfikacji (1, X, 2).

- ✓ Rzeczywiste dane meczowe
- ✓ Wysoki potencjał *Feature Engineeringu*
- ✓ Gotowość do klasyfikacji wieloklasowej



2. Analiza Zbioru Danych: Zmienne



Zmienne Numeryczne

Ciągłe i dyskretne wskaźniki efektywności. Obejmują m.in. **posiadanie piłki (%)**, **liczbę strzałów** (celnych i niecelnych), **rzuty różne** oraz zdobyte gole.



Zmienne Kategoryczne


Obejmują **nazwy drużyn** (gospodarze, goście), **ligę** oraz **datę meczu**. Wymagają transformacji (np. One-Hot Encoding) przed podaniem do modeli matematycznych.




Zmienna Docelowa

Wyliczona z bramek kolumna wyników. Trzy kategorie: **1** (wygrana gospodarzy), **X** (remis) lub **2** (wygrana gości). Problem wieloklasowy.

2. Analiza Zbioru Danych: Rozkład wyników




2. Analiza Zbioru Danych: Macierz korelacji



Rozkład Zmiennej Docelowej

Analiza (Countplot) wykazuje naturalny dla piłki nożnej brak pełnego zbalansowania klas. Zdecydowaną przewagę mają wygrane gospodarzy.

Dla algorytmów AI (szczególnie drzewiastych) takie niezbalansowanie wymusza uważny dobór metryk – zamiast zwykłego *Accuracy*, kluczowy będzie *F1-Score* lub *Balanced Accuracy*.



2. Analiza Zbioru Danych: Jakość Danych

Obsługa Braków w Danych

W danych historycznych często występują braki dla niższych lig (brak pomiaru np. posiadania piłki). Nasze podejście analityczne:

- Usunięcie spotkań z krytyczną liczbą pustych wartości (poniżej 50% zawartości danych).
- **Imputacja:** Zastąpienie braków w statystykach medianą obliczoną dla danej ligi, aby zachować sensowność danych i nie tracić rozmiaru zbioru.

Analiza Korelacji

Macierz korelacji Pearsona ukazuje najistotniejsze zależności liniowe między statystykami a wynikiem:

- Silna, pozytywna korelacja między **liczbą celnych strzałów** a ostateczną liczbą goli gospodarzy.
- Zaskakująco niska korelacja **samego posiadania piłki** u gości z ich szansą na wygraną.

3. Sformułowanie Hipotezy

Zastosowanie zaawansowanych algorytmów uczenia maszynowego (Gradient Boosting / Random Forest) opartych na agregowanych statystykach przedmeczowych, pozwoli na przewidywanie wyniku meczu z precyzją wyższą niż 55%, znacznie przekraczając klasyczny baseline losowości i dając wymierną wartość w analizie bukmacherskiej.

4. Aktualny Stan Wiedzy



Podejścia Statystyczne

Historycznie dominowały modele bazujące na **Rozkładzie Poissona** (szacowanie siły ataku/obrony) oraz systemy rankingowe (np. modyfikacje **Elo Rating**).



Machine Learning

Obecny standard branżowy.
Algorytmy zespołowe: **XGBoost**, **LightGBM** i **Lasy Losowe** skutecznie wyłapują nieliniowe zależności z danych tabelarycznych.



Deep Learning

Najnowsze badania eksperymentują z sieciami sekwencyjnymi (**RNN/LSTM**), analizując mecze jako ułożone w czasie zjawiska do odczytania trendów i formy drużyn.

4. Kluczowa Literatura Przedmiotu

A machine learning framework for sport result prediction

Bunker & Thabtah, 2019

- Wprowadza dedykowane ramy pracy (tzw. framework SRP-CRISP-DM) specjalnie dla procesowania danych sportowych.
- Podkreśla, że w sporcie tradycyjna kros-walidacja się nie sprawdza – dane muszą być testowane chronologicznie (runda po rundzie)

Prediction of football match results with Machine Learning

Rodrigues & Pinto, 2022

- Porównanie skuteczności różnych algorytmów (m.in. Random Forest, SVM, XGBoost) na meczach angielskiej Premier League.
- Autorzy wzbogacili statystyki historyczne o oceny umiejętności piłkarzy z bazy gry FIFA
- Najwyższą skuteczność (65,26%) i zyskowność osiągnął model Random Forest po rygorystycznej selekcji cech

A physics-based algorithm to perform predictions in football leagues

Stock, da Silva, Fernandes, 2022

- Podejście alternatywne do ML: wykorzystanie modeli stochastycznych (fizycznych) do przewidywania wyników ligowych.
- Algorytm symuluje rozkład bramek (rozkład Poissona) bazując na wyliczonym "potencjale" drużyny (forma sportowa + wartość rynkowa)
- Wyniki modelu są porównywalne z wysoce zaawansowanym, komercyjnym systemem SPI (FiveThirtyEight)